

Пространственная репрезентация российских городов в песенных текстах: анализ топонимов с использованием LLM



Злобин Дмитрий
Игоревич
ПЗАД-4
БСЦ231




Кияница Владислав
Игоревич
ПЗАД-4
БГП231



Холодов Тимур
Алексеевич
ПЗАД-3
БПЛТЛ232



Юрова Ксения
Валерьевна
ПЗАД-4
БГП231




Блуменау Марк Ильич
Департамент больших
данных и информационного
поиска

Проблема исследования

Несмотря на активное развитие и широкое применение методов машинного обучения в Digital Humanities, в частности NER, демонстрирующих высокую точность на качественно отредактированных текстах, легко обнаружить, что их эффективность существенно снижается при работе с песенными текстами, наполненными неформальной лексикой: например, слэнгом

Это привело нас к исследовательскому вопросу:

Как дообучить LLM-модель для работы с неформальными, контекстными и сленговыми упоминаниями топонимов городов России в песенных текстах?



Что изучаем?

Русскоязычные песенные тексты как источник пространственных упоминаний о городе, а также возможность автоматически извлекать из них топонимы с помощью LLM

Почему изучаем?

Песенные тексты фиксируют культурные представления о городе: его районы, улицы, знаковые места, символические границы и связанные с ними смыслы. При этом стандартные NER-модели плохо работают с песнями, так как в них много сленга, сокращений, разговорных и контекстных упоминаний, поэтому нужен более адаптированный технический подход.

Что хотим сделать?

Дообучить и оценить LLM-модель, которая сможет извлекать топонимы из русскоязычных песенных текстов, включая неформальные и сложные случаи.

Что предполагаем?

Дообучение LLM-модели на специализированно размеченном корпусе русскоязычных песенных текстов позволит повысить качество извлечения топонимов по сравнению с базовыми NER-подходами, особенно в случаях неформальных, сленговых, сокращенных и контекстных упоминаний.

Как именно изучаем?

1. Собираем массив песенных текстов, содержащих упоминания локаций и топонимов городов России.
2. Подготавливаем и размечаем данные для дообучения модели на задаче распознавания топонимов.
3. Дообучаем LLM-модель для извлечения топонимов городов России из песенных текстов.
4. Проверяем качество работы модели на корпусе песенных текстов и выявить особенности распознавания топонимов в сложных языковых случаях.
5. Сравниваем и описываем результаты дообученной LLM и базовой LLM на тестовой выборке.
6. Проводим постобработку извлеченных топонимов, включая их нормализацию и приведение к единому виду.
7. Выполняем геокодирование распознанных топонимов и сопоставляем их с конкретными объектами городской среды.
8. Проводим анализ полученных данных, включая частоту упоминаний, пространственное распределение, эмоциональную окраску и тематические связи топонимов.
9. Визуализируем результаты исследования в виде карты топонимов и сопутствующих статистических материалов.

Откуда берем данные?

Готовый датасет на HuggingFace

lyricgenius + spotify

Russian Rap 2017-2022 dataset*

Как оцениваем результаты?

Precision

Recall

F1-score

Что с ними делаем?

1

Подготовка
и разметка корпуса
песенных текстов

2

Предобработка текстов

3

Извлечения топонимов

4

Нормализации
и геокодирования

5

Проведение
пространственного
и содержательного
анализа распознанных
топонимов

* – <https://www.kaggle.com/datasets/timursharifullindata/russian-rap-2017-2022-dataset>

Литература

А) Культурные тексты как источник пространственной репрезентации города

1. Колмогорова, А. В. (2025). Топонимы в советском песенном дискурсе (1964–1991): корпусное исследование. Вопросы ономастики, 22(2), 148–182. https://doi.org/10.15826/vopr_onom.2025.22.2.020
2. Kuo, A.-T., & Samet, H. (2021). MusicStand: Listening to song lyrics using a map query interface. In Proceedings of the 29th International Conference on Advances in Geographic Information Systems (SIGSPATIAL '21) (4 pp.). Association for Computing Machinery. <https://doi.org/10.1145/3474717.3484211>
3. Heuser, R., Moretti, F., & Steiner, E. (2016). The emotions of London. Pamphlets of the Stanford Literary Lab, 13, 1–10.

Б) NER и адаптация моделей к нестандартным корпусам

1. Keraghel, I., Morbieu, S., & Nadif, M. (2024). Recent advances in named entity recognition: A comprehensive survey and comparative study [Preprint]. HAL. <https://hal.science/hal-04488194v2>
2. Атнашев, Т., Ганеева, В., Казаков, Р., Матяш, Д., Сонкин, М., Волошина, Е., Сериков, О., & Артемова, Е. (2022). Размечено: Распознавание именованных сущностей в цифровом архиве дневников «Прожито». In Материалы Пятой международной конференции по компьютерной лингвистике в Болгарии (CLIB 2022) (с. 22–38).
3. Sánchez de Lamadrid, D. Z., & Garrido-Merchán, E. C. (2026). Fine-tuning large language models for automatic detection of sexually explicit content in Spanish-language song lyrics [Preprint]. arXiv. <https://arxiv.org/abs/2602.05485>

В) Геопарсинг, распознавание локационных упоминаний и разрешение топонимов

1. Gritta, M., Pilehvar, M. T., & Collier, N. (2020). A pragmatic guide to geoparsing evaluation: Toponyms, named entity recognition and pragmatics. Language Resources and Evaluation, 54, 683–712. <https://doi.org/10.1007/s10579-019-09475-3>
2. Hu, X., Zhou, Z., Li, H., Hu, Y., Gu, F., Kersten, J., Fan, H., & Klan, F. (2023). Location reference recognition from texts: A survey and comparison. ACM Computing Surveys, 56(5), Article 112. <https://doi.org/10.1145/3625819>
3. DeLozier, G., Wing, B., Baldridge, J., & Nesbit, S. (2016). Creating a novel geolocation corpus from historical texts. In Proceedings of LAW X: The 10th Linguistic Annotation Workshop (pp. 188–198). Association for Computational Linguistics.
4. Hu, X., Kersten, J., Klan, F., & Farzana, S. M. (2026). Toponym resolution leveraging lightweight and open-source large language models and geo-knowledge. International Journal of Geographical Information Science, 40(3), 670–697. <https://doi.org/10.1080/13658816.2024.2405182>
5. Hu, Y., Mai, G., Cundy, C., Choi, K., Lao, N., Liu, W., Lakhapal, G., Zhou, R. Z., & Joseph, K. (2023). Geo-knowledge-guided GPT models improve the extraction of location descriptions from disaster-related social media messages. International Journal of Geographical Information Science, 37(11), 2289–2318. <https://doi.org/10.1080/13658816.2023.2266495>

Основные этапы работы и предполагаемые результаты



Выбор команды и темы проекта Изучение основных подходов и методов в похожих исследованиях Сбор и обработка данных Подбор наилучшего способа fine-tuning'a LLM Анализ и интерпретация полученных результатов Создание сайта

