

Кияница Владислав Игоревич (ПЗАД-4)  
Злобин Дмитрий Игоревич (ПЗАД-4)

Юрова Ксения Валерьевна (ПЗАД-4)  
Холодов Тимур Алексеевич (ПЗАД-3)

Куратор – Блуменау Марк Ильич

## **Пространственная репрезентация российских городов в песенных текстах: анализ топонимов с использованием LLM<sup>1</sup>**

### **Ключевые слова**

LLM, NLP, fine-tuning, топоним, извлечение географической информации

### **Актуальность**

Актуальность исследования определяется тем, что сегодня в гуманитарных и социальных науках все более востребованными становятся методы анализа нерективных данных, то есть данных, которые возникают независимо от исследователя и фиксируют уже существующие в обществе смыслы, представления и культурные формы. Одним из таких источников являются тексты песен, поскольку в них отражаются устойчивые образы, например, города. В записанных текстом данных содержатся устоявшиеся представления о его районах, улицах, знаковых местах и символических границах. Для городской тематики это позволяет рассматривать культурные тексты как источник сведений о том, как пространство воспринимается, называется и наделяется значением.

При этом, развитие больших языковых моделей открывает новые возможности для автоматической обработки подобных данных, в том числе для извлечения сложных и нестандартных упоминаний городских топонимов из текстов, написанных в свободной, разговорной или художественной манере. В результате становится возможным перейти от отдельных наблюдений к системному анализу: выявлять, какие локации чаще всего появляются в песнях, как они распределены в пространстве, какие эмоциональные и тематические ассоциации с ними связаны, как меняется их упоминаемость во времени и какой образ складывается в музыкальном представлении о городе. Тем самым, актуальность работы связана и с развитием цифровых методов в социальных науках, урбанистике<sup>2</sup> и Digital Humanities<sup>3</sup>, и указывает на потенциальную возможность предложить технически обоснованный способ изучения символической репрезентации городов на материале песенных текстов.

### **Исследовательская проблема**

Несмотря на активное развитие Digital Humanities и рост интереса к использованию методов машинного и глубинного обучения в гуманитарных и социальных науках, в российском контексте пока слабо разработаны подходы, позволяющие автоматически извлекать и анализировать пространственные упоминания города в неформальных текстах. Особенно это касается песенных текстов, где названия локаций часто употребляются в разговорной, сокращенной, сленговой или контекстной форме, что в разы затрудняет их распознавание стандартными NER-моделями. Иными словами, существующие инструменты

---

<sup>1</sup> <https://github.com/kseniyayurova/iad>

<sup>2</sup> <https://sysblok.ru/category/urban/>

<sup>3</sup> [https://sysblok.ru/category/digital\\_humanities/](https://sysblok.ru/category/digital_humanities/)

автоматического извлечения именованных сущностей недостаточно хорошо подходят для работы с песенными текстами как с источником данных о символическом и эмоциональном восприятии города, что создает необходимость разработки более адаптивного технического подхода, основанного на дообучении LLM-модели, который позволил бы распознавать топонимы в сложных языковых контекстах.

## **Исследовательский вопрос**

Как дообучить LLM-модель для работы с неформальными, контекстными и сленговыми упоминаниями топонимов городов России в песенных текстах?

## **Объект**

Русскоязычные песенные тексты, в которых упоминаются пространственные локации и топонимы.

## **Предмет**

Дообучение LLM-модели для извлечения топонимов из русскоязычных текстов песен и оценка качества ее работы.

## **Концептуализация основных понятий**

**LLM** - предобученная нейросетевая модель, обладающая общими знаниями о языке.

**NLP** - область искусственного интеллекта и компьютерной лингвистики, связанная с автоматическим анализом и обработкой текстов на естественном языке.

**Fine-tuning** - процесс адаптации LLM к конкретной задаче извлечения топонимов на специализированном размеченном корпусе песенных текстов. В отличие от использования модели “как есть”, дообучение позволяет учитывать языковую специфику, в том числе разговорные, сокращенные, сленговые и контекстно существующие формы упоминания локаций.

**Топоним** - языковое обозначение географического объекта, которое может быть соотнесено с определенной локацией. В данной работе под топонимами понимаются официальные географические названия, сленговые формы, сокращения, а также контекстные пространственные обозначения.

**Извлечением географической информации** - процесс автоматического обнаружения в тексте фрагментов, содержащих пространственно значимую информацию. Этот процесс включает прежде всего выделение топонимических упоминаний из текста, их последующую нормализацию и подготовку к географической интерпретации.

**Обучающий датасет** - корпус песенных текстов, для которых сформирован эталонный список сущностей в указанном формате.

## **Операционализация**

Основным подходом в проекте выступает дообучение LLM в рамках задачи извлечения топонимов из русскоязычных песенных текстов. Перечислим основные категории, а также формирующий их подход для решения данной задачи:

1. Единицей входных данных выступает отдельный текст песни. Единицей разметки – сущность (в рамках работы – слово/словосочетание, обозначающее пространственное местоположение) в тексте. Датасет создается в два этапа: сначала разметка составляется при помощи LLM, затем результаты проверяются вручную и приводятся к единому формату. Целевая переменная в исследовании – корректное предсказание списка сущностей для каждого текста.

2. Дообучением LLM происходит за счет адаптации предобученной модели на размеченном корпусе. Для работы была выбрана базовая модель Qwen/Qwen3.5-9B. В дальнейшей работе базовая модель может быть изменена, например, на вариацию с большим числом параметров в случае обнаружения более подходящей под цели исследования модели, однако на текущий момент было принято решение остановиться на данной модели, поскольку среди всех экспериментов с доступными для запуска на имеющихся ресурсах open-source моделями она зарекомендовала себя наилучшим образом. В качестве основного способа адаптации планируется использовать fine-tuning или же LoRA. Также произведем попытку применения Prompt tuning как альтернативный вариант дообучения модели.
3. Качество модели измеряется через стандартные метрики для задачи распознавания: precision, recall и F1-score. Precision показывает долю корректных объектов среди всех предсказанных моделью. Recall показывает долю объектов из эталонной разметки, которые модель смогла найти. F1-score будет использоваться для интегральной оценки модели в случае наличия сомнений в выборе конкретного варианта решения.

## Цель

Дообучить и оценить LLM-модель для извлечения топонимов городов России из песенных текстов, включая их неформальные и контекстные упоминания.

## Задачи

1. Собрать массив песенных текстов, содержащих упоминания локаций и топонимов городов и мест в них в России.
2. Подготовить и разметить данные для дообучения модели на задаче распознавания топонимов.
3. Дообучить LLM-модель для извлечения топонимов городов России из песенных текстов.
4. Проверить качество работы модели на корпусе песенных текстов и выявить особенности распознавания топонимов в сложных языковых случаях.
5. Сравнить и описать результаты дообученной LLM и базовой LLM на тестовой выборке.
6. Провести постобработку извлеченных топонимов, включая их нормализацию и приведение к единому виду.
7. Выполнить геокодирование распознанных топонимов и сопоставить их с конкретными объектами городской среды.
8. Провести анализ полученных данных, включая частоту упоминаний, пространственное распределение, эмоциональную окраску и тематические связи топонимов.
9. Визуализировать результаты исследования в виде карты распознанных локаций с модулем фильтрации и отображением дополнительно определенных характеристик.

## Гипотеза

Дообучение LLM-модели на специализированно размеченном корпусе русскоязычных песенных текстов позволит повысить качество извлечения топонимов по сравнению с базовыми NER-подходами, особенно в случаях неформальных, сленговых, сокращенных и контекстных упоминаний.

## Обзор литературы

Исследование пространственной репрезентации российских городов в песенных текстах находится на стыке трех направлений: анализа культурных текстов как носителей пространственных образов, NER для извлечения сущностей из нестандартных текстов и сбора топонимов как пайплайна распознавания, нормализации и получения пространственно привязанных локальных объектов. Ключевая проблема состоит в разрыве между этими традициями. Культурные исследования показывают, зачем анализировать топонимы в текстах, а технические – как их извлекать.

Этот разрыв особенно заметен в российском контексте. Некоторые работы показывают аналитический потенциал песенного корпуса, но не решает задачу автоматического извлечения сложных внутригородских упоминаний. Другие, в свою очередь, говорят что для русского нестандартного корпуса NER требует отдельной разметки и настройки моделей. Поэтому дообучение LLM для русскоязычных песенных текстов выступает не как частная техническая настройка, а как самостоятельная исследовательская задача.

Цель обзора литературы – показать, как существующие работы позволяют осмыслить задачу извлечения, нормализации и геокодирования топонимов из русскоязычных песенных текстов.

### А) Культурные тексты как источник пространственной репрезентации города

Первый блок литературы демонстрирует взгляд на песенные и художественные тексты как источник пространственных данных, но в различных исследованиях по-разному понимается сама цель такой работы. У Колмогоровой [1] топонимы используются для историко-дискурсивной интерпретации, через которые выявляются идеологические сдвиги, миграционные процессы и символическая картина мира. У Куо и Samet [3] песенный текст, напротив, выступает как объект технической обработки и географического поиска. У Heuser, Moretti и Steiner [7] топонимы становятся основой для перехода к следующему аналитическому уровню – эмоциональной картографии.

Различие между работами проходит не по материалу, а по исследовательской оптике. Интерпретация, поиск или последующий анализ контекстов. Рассмотрение этих работ показывает уже доказанную пригодность культурных текстов для анализа в пространственном ключе, но одновременно обозначает ограниченность самой сущности, а именно опору в исследованиях на уже извлеченные топонимы, что почти не решает задачу надежного автоматического извлечения сложных пространственных упоминаний из различных корпусов информации.

### Б) NER и адаптация моделей к нестандартным корпусам

Второй блок литературы показывает, что качество распознавания сущностей определяется и архитектурой модели, и свойствами корпуса литературы. Keraghel, Morbieu и Nadif[6] описывают развитие NER от систем на основе правил к трансформерам и большим языковым моделям и отдельно подчеркивают значимость малого количества размеченных данных. Песенные тексты как раз представляют случай сильного расхождения с типовыми обучающими корпусами.

Проблему такого расхождения особенно ясно показывает Атнашев Т. и др.[11]. На материале дневников авторы демонстрируют, что модели, обученные на новостных корпусах, теряют качество на нестандартных русских текстах. Это прямой аргумент в пользу того, что русскоязычные песни нельзя рассматривать как обычный корпус, они требуют собственной разметки и отдельной настройки модели. Схожий вывод на песенном материале делают Sánchez de Lamadrid и Garrido-Merchán[2]. Они показывают, что сленг, метафоры и культурно специфические двойные смыслы делают недостаточными словарные и

основанные на жестких правилах подходы, тогда как дообучение GPT на небольшом специально собранном корпусе дает заметный прирост качества.

Исходя из анализа этих исследований, становится понятно, что ключевая проблема состоит не в выборе «лучшей» модели, а в соответствии модели корпусу. Однако для нашей задачи нужно не только выделить локацию, но и определить, что считать пространственным упоминанием, как снимать неоднозначность и как связывать выражение с конкретным местом.

#### В) Геопарсинг, распознавание локационных упоминаний и разрешение топонимов

Третий блок задает техническую рамку исследования. Gritta, Pilehvar и Collier[5] рассматривают геопарсинг как двухэтапный процесс: сначала из текста выделяются топонимы, затем они соотносятся с конкретными географическими координатами. Топоним нельзя понимать только как простое название места, в реальных текстах важны контекст и тип употребления. Поэтому они предлагают более детальную классификацию топонимов, новую систему оценки и специальный корпус данных. Для исследования это релевантно, поскольку позволяет рассматривать задачу как более сложную обработку пространственной информации в тексте, а не как обычный NER.

Обзор Hu et al.[9] дополняет эту рамку, показывая, что первый шаг такой обработки – распознавание пространственных упоминаний. К ним относятся топонимы и более сложные описания места, включающие направление, расстояние и пространственные связи. Они также отмечают сложность неформальной специфики, как звучало ранее. В нашем случае, неформальная специфика проявляется в песенных текстах, так как пространственно значимыми могут быть не только официальные названия, но и контекстные описания мест. Похожую проблему с другой стороны показывает DeLozier et al.[8], даже в специально размеченных корпусах сохраняются неоднозначность, размытость границ задачи и нехватка подходящих данных.

Дальнейшие работы Hu et al.[4, 10] показывают переход к большим языковым моделям. Авторы доказывают, что обычные модели плохо выделяют полные описания места, тогда как сочетание языковой модели с географическим знанием заметно улучшает результат. Главный шаг – модель сначала восстанавливает, какое именно место имеется в виду, а затем результат уточняется с помощью внешних географических баз. Тем самым современная литература движется от базовых NER к гибридным подходам, сочетающим языковую модель и различное знание.

#### Вывод

Исследование находится на пересечении трех главных направлений. Оно рассматривает песенные тексты как источник пространственных образов города, опирается на вывод о том, что для такого материала нужны собственная разметка и дообучение модели, и использует логику геопарсинга, где важно не только выделить топоним, но и привести его к стандартизованному виду, снять неоднозначность и связать с конкретным объектом на карте.

## Методы

- 1) На первом этапе предполагается **подготовка и разметка корпуса песенных текстов**. Литература по NER показывает, что большинство существующих датасетов построено на новостях, научных текстах и Википедии, поэтому перенос моделей на другой жанр требует отдельного корпуса и отдельной процедуры адаптации. Корпус песенных текстов будет размечаться вручную или в формате LLM-assisted с последующей человеческой верификацией.

- 2) На втором этапе предполагается **предобработка текстов**. Поскольку лирические тексты часто бывают плохо капитализированы, неформальны и содержат шум, качество стандартного NER заметно падает.
- 3) На третьем этапе используется **двухуровневая схема извлечения топонимов**. В качестве простого baseline можно использовать готовые NER-инструменты для русского языка. (Используем Natasha, DeepPavlovBERT NER, Stanza и spaCy). Однако основным методом в исследовательской работе выступает не готовый NER «из коробки», а **дообученная open-source LLM (в нашем случае Qwen/Qwen3.5-9B)**, поскольку исследования по domain adaptation показывают, что именно fine-tuning помогает модели работать со сленгом, метафорами, культурно-специфическими выражениями и нестандартными конструкциями. Содержательно основная модель должна извлекать не только отдельные «официальные» топонимы, но и **полные пространственные описания**, если они встречаются в тексте.
- 4) После извлечения топонимов необходим этап **нормализации и геокодирования**. Здесь наиболее обоснован именно гибридный подход, а не попытка решать все только силами LLM, поскольку LLM удобны для восстановления однозначной ссылки на место из контекста, но не обладают полным geo-knowledge, и поэтому их следует сочетать с внешними географическими сервисами. Сначала open-source LLM будет дообучаться для определения однозначного референта, а затем результат будет уточняться через GeoNames, Nominatim и QGIS geocoders. (К слову, в том числе поэтому следует приводить к нормализованному виду, а не оставлять в виде «сырых» текстовых фрагментов).
- 5) Наконец, после технической обработки возможен **пространственный и содержательный анализ** распознанных топонимов: частотный анализ, картографирование, анализ контекстов употребления, тематических и эмоциональных связей.

## Метрики качества

1. Precision, recall и F1-score
2. Accuracy@161km, AUC и Mean Error




Рис.1. Заметки с брейншторма

## Данные

На данном этапе работы сложно точно определить, какой набор данных будет достаточным для выполнения поставленных задач. Однако существует несколько открытых фреймворков и датасетов, которые могут быть потенциально использованы для выполнения проекта:

1. Готовый датасет на HuggingFace – уже собранный массив данных, содержащий 193 тысячи уникальных песен, включая их название, автора и сам текст песни.
2. lyricgenius + spotify – в случае, если для реализации проекта данных из п. 1 будет недостаточно, то есть возможность дополнить датасет, обращаясь к SpotifyAPI (затруднительно, учитывая их ограничения, но любой другой сервис также может подойти) или уже выгруженные данные, в которых редко указан текст песни, однако его можно получить используя Genius.
3. Альтернативные датасеты: например, Russian Rap 2017-2022 dataset<sup>4</sup>. Они значительно меньше по объему и частично содержат композиции уже существующие в массиве из п. 1, однако они так же содержат отсутствующие там же композиции, что позволит увеличить имеющуюся выборку.

## Ограничения

На данный момент основным ограничением выступает ограниченность данных, поскольку из указанных почти 200 тысяч песен лишь малая часть удовлетворяет требованиям исследования (текст песни на русском, в тексте песни имеется информация о топониме и т.п.).

Помимо прочего, во время разметки песенных текстов команда столкнулась с проблемой нехватки оперативной памяти и низкой скоростью работы библиотеки Transformers от Hugging Face. В качестве решения проблемы было принято решение использования библиотеки vLLM. Проблема находится в стадии разработки и поиска наилучшего решения для оптимизации времени обработки песенных текстов для разметки данных.

---

<sup>4</sup> <https://www.kaggle.com/datasets/timursharifullindata/russian-rap-2017-2022-dataset>

## Список литературы

1. Колмогорова, А. В. (2025). Топонимы в советском песенном дискурсе (1964–1991): корпусное исследование. Вопросы ономастики, 22(2), 148–182.  
[https://doi.org/10.15826/vopr\\_onom.2025.22.2.020](https://doi.org/10.15826/vopr_onom.2025.22.2.020)
2. Sánchez de Lamadrid, D. Z., & Garrido-Merchán, E. C. (2026). Fine-tuning large language models for automatic detection of sexually explicit content in Spanish-language song lyrics [Preprint]. arXiv.  
<https://arxiv.org/abs/2602.05485>
3. Kuo, A.-T., & Samet, H. (2021). MusicStand: Listening to song lyrics using a map query interface. In Proceedings of the 29th International Conference on Advances in Geographic Information Systems (SIGSPATIAL '21) (4 pp.). Association for Computing Machinery. <https://doi.org/10.1145/3474717.3484211>
4. Hu, X., Kersten, J., Klan, F., & Farzana, S. M. (2026). Toponym resolution leveraging lightweight and open-source large language models and geo-knowledge. International Journal of Geographical Information Science, 40(3), 670–697. <https://doi.org/10.1080/13658816.2024.2405182>
5. Gritta, M., Pilehvar, M. T., & Collier, N. (2020). A pragmatic guide to geoparsing evaluation: Toponyms, named entity recognition and pragmatics. Language Resources and Evaluation, 54, 683–712.  
<https://doi.org/10.1007/s10579-019-09475-3>
6. Keraghel, I., Morbieu, S., & Nadif, M. (2024). Recent advances in named entity recognition: A comprehensive survey and comparative study [Preprint]. HAL. <https://hal.science/hal-04488194v2>
7. Heuser, R., Moretti, F., & Steiner, E. (2016). The emotions of London. Pamphlets of the Stanford Literary Lab, 13, 1–10.
8. DeLozier, G., Wing, B., Baldridge, J., & Nesbit, S. (2016). Creating a novel geolocation corpus from historical texts. In Proceedings of LAW X: The 10th Linguistic Annotation Workshop (pp. 188–198). Association for Computational Linguistics.
9. Hu, X., Zhou, Z., Li, H., Hu, Y., Gu, F., Kersten, J., Fan, H., & Klan, F. (2023). Location reference recognition from texts: A survey and comparison. ACM Computing Surveys, 56(5), Article 112.  
<https://doi.org/10.1145/3625819>
10. Hu, Y., Mai, G., Cundy, C., Choi, K., Lao, N., Liu, W., Lakhanpal, G., Zhou, R. Z., & Joseph, K. (2023). Geo-knowledge-guided GPT models improve the extraction of location descriptions from disaster-related social media messages. International Journal of Geographical Information Science, 37(11), 2289–2318.  
<https://doi.org/10.1080/13658816.2023.2266495>
11. Атнашев, Т., Ганеева, В., Казаков, Р., Матяш, Д., Сонкин, М., Волошина, Е., Сериков, О., & Артемова, Е. (2022). Размечено: Распознавание именованных сущностей в цифровом архиве дневников «Прожито». In Материалы Пятой международной конференции по компьютерной лингвистике в Болгарии (CLIB 2022) (с. 22–38).