

Кияница Владислав Игоревич (ПЗАД-4)
Злобин Дмитрий Игоревич (ПЗАД-4)

Юрова Ксения Валерьевна (ПЗАД-4)
Холодов Тимур Алексеевич (ПЗАД-3)

Куратор – Блуменау Марк Ильич

Пространственная репрезентация российских городов в песенных текстах: анализ топонимов с использованием LLM¹

Ключевые слова

LLM, NLP, fine-tuning, топоним, извлечение географической информации

Актуальность

Актуальность исследования определяется тем, что сегодня в гуманитарных и социальных науках все более востребованными становятся методы анализа нерективных данных, то есть данных, которые возникают независимо от исследователя и фиксируют уже существующие в обществе смыслы, представления и культурные формы. Одним из таких источников являются тексты песен, поскольку в них отражаются устойчивые образы, например, города. В записанных текстом данных содержатся устоявшиеся представления о его районах, улицах, знаковых местах и символических границах. Для городской тематики это позволяет рассматривать культурные тексты как источник сведений о том, как пространство воспринимается, называется и наделяется значением.

При этом, развитие больших языковых моделей открывает новые возможности для автоматической обработки подобных данных, в том числе для извлечения сложных и нестандартных упоминаний городских топонимов из текстов, написанных в свободной, разговорной или художественной манере. В результате становится возможным перейти от отдельных наблюдений к системному анализу: выявлять, какие локации чаще всего появляются в песнях, как они распределены в пространстве, какие эмоциональные и тематические ассоциации с ними связаны, как меняется их упоминаемость во времени и какой образ складывается в музыкальном представлении о городе. Тем самым, актуальность работы связана и с развитием цифровых методов в социальных науках, урбанистике² и Digital Humanities³, и указывает на потенциальную возможность предложить технически обоснованный способ изучения символической репрезентации городов на материале песенных текстов.

Исследовательская проблема

Несмотря на активное развитие Digital Humanities и рост интереса к использованию методов машинного и глубинного обучения в гуманитарных и социальных науках, в российском контексте пока слабо разработаны подходы, позволяющие автоматически извлекать и анализировать пространственные упоминания города в неформальных текстах. Особенно это касается песенных текстов, где названия локаций часто употребляются в разговорной, сокращенной, сленговой или контекстной форме, что в разы затрудняет их распознавание стандартными NER-моделями. Иными словами, существующие инструменты

¹ <https://github.com/kseniyayurova/iad>

² <https://sysblok.ru/category/urban/>

³ https://sysblok.ru/category/digital_humanities/

автоматического извлечения именованных сущностей недостаточно хорошо подходят для работы с песенными текстами как с источником данных о символическом и эмоциональном восприятии города, что создает необходимость разработки более адаптивного технического подхода, основанного на дообучении LLM-модели, который позволил бы распознавать топонимы в сложных языковых контекстах.

Исследовательский вопрос

Как дообучить LLM-модель для работы с неформальными, контекстными и сленговыми упоминаниями топонимов городов России в песенных текстах?

Объект

Русскоязычные песенные тексты, в которых упоминаются пространственные локации и топонимы.

Предмет

Дообучение LLM-модели для извлечения топонимов из русскоязычных текстов песен и оценка качества ее работы.

Концептуализация основных понятий

LLM - предобученная нейросетевая модель, обладающая общими знаниями о языке.

NLP - область искусственного интеллекта и компьютерной лингвистики, связанная с автоматическим анализом и обработкой текстов на естественном языке.

Fine-tuning - процесс адаптации LLM к конкретной задаче извлечения топонимов на специализированном размеченном корпусе песенных текстов. В отличие от использования модели “как есть”, дообучение позволяет учитывать языковую специфику, в том числе разговорные, сокращенные, сленговые и контекстно существующие формы упоминания локаций.

Топоним - языковое обозначение географического объекта, которое может быть соотнесено с определенной локацией. В данной работе под топонимами понимаются официальные географические названия, сленговые формы, сокращения, а также контекстные пространственные обозначения.

Извлечением географической информации - процесс автоматического обнаружения в тексте фрагментов, содержащих пространственно значимую информацию. Этот процесс включает прежде всего выделение топонимических упоминаний из текста, их последующую нормализацию и подготовку к географической интерпретации.

Обучающий датасет - корпус песенных текстов, для которых сформирован эталонный список сущностей в указанном формате.

Операционализация

Основным подходом в проекте выступает дообучение LLM в рамках задачи извлечения топонимов из русскоязычных песенных текстов. Перечислим основные категории, а также формирующий их подход для решения данной задачи:

1. Единицей входных данных выступает отдельный текст песни. Единицей разметки – сущность (в рамках работы – слово/словосочетание, обозначающее пространственное местоположение) в тексте. Датасет создается в два этапа: сначала разметка составляется при помощи LLM, затем результаты проверяются вручную и приводятся к единому формату. Целевая переменная в исследовании – корректное предсказание списка сущностей для каждого текста.

2. Дообучением LLM происходит за счет адаптации предобученной модели на размеченном корпусе. Для работы была выбрана базовая модель Qwen/Qwen3.5-9B. В дальнейшей работе базовая модель может быть изменена, например, на вариацию с большим числом параметров в случае обнаружения более подходящей под цели исследования модели, однако на текущий момент было принято решение остановиться на данной модели, поскольку среди всех экспериментов с доступными для запуска на имеющихся ресурсах open-source моделями она зарекомендовала себя наилучшим образом. В качестве основного способа адаптации планируется использовать fine-tuning или же LoRA. Также произведем попытку применения Prompt tuning как альтернативный вариант дообучения модели.
3. Качество модели измеряется через стандартные метрики для задачи распознавания: precision, recall и F1-score. Precision показывает долю корректных объектов среди всех предсказанных моделью. Recall показывает долю объектов из эталонной разметки, которые модель смогла найти. F1-score будет использоваться для интегральной оценки модели в случае наличия сомнений в выборе конкретного варианта решения.

Цель

Дообучить и оценить LLM-модель для извлечения топонимов городов России из песенных текстов, включая их неформальные и контекстные упоминания.

Задачи

1. Собрать массив песенных текстов, содержащих упоминания локаций и топонимов городов и мест в них в России.
2. Подготовить и разметить данные для дообучения модели на задаче распознавания топонимов.
3. Дообучить LLM-модель для извлечения топонимов городов России из песенных текстов.
4. Проверить качество работы модели на корпусе песенных текстов и выявить особенности распознавания топонимов в сложных языковых случаях.
5. Сравнить и описать результаты дообученной LLM и базовой LLM на тестовой выборке.
6. Провести постобработку извлеченных топонимов, включая их нормализацию и приведение к единому виду.
7. Выполнить геокодирование распознанных топонимов и сопоставить их с конкретными объектами городской среды.
8. Провести анализ полученных данных, включая частоту упоминаний, пространственное распределение, эмоциональную окраску и тематические связи топонимов.
9. Визуализировать результаты исследования в виде карты распознанных локаций с модулем фильтрации и отображением дополнительно определенных характеристик.

Гипотеза

Дообучение LLM-модели на специализированно размеченном корпусе русскоязычных песенных текстов позволит повысить качество извлечения топонимов по сравнению с базовыми NER-подходами, особенно в случаях неформальных, сленговых, сокращенных и контекстных упоминаний.

Обзор литературы

Исследование пространственной репрезентации российских городов в песенных текстах находится на стыке двух направлений: анализа культурных текстов как носителей пространственных образов, NER для извлечения сущностей из нестандартных текстов и сбора топонимов как элемента распознавания.

Исследования из сферы культуры показывают, зачем анализировать топонимы в текстах, а технические – как их извлекать.

Цель обзора литературы – показать, как в существующих работах решалась задача распознавания, нормализации и геокодирования топонимов из текстов песен.

А) Культурные тексты как источник пространственной репрезентации города

У Колмогоровой топонимы используются для историко-дискурсивной интерпретации, через которые выявляются идеологические сдвиги, миграционные процессы и символическая картина мира. Heuser, Moretti и Steiner используют топонимы как основу для перехода к следующему аналитическому уровню – эмоциональной картографии.

Различие между работами проходит не по материалу, а по исследовательской оптике. Интерпретация, поиск или последующий анализ контекстов. Рассмотрение этих работ показывает уже доказанную пригодность культурных текстов для анализа в пространственном ключе, но одновременно обозначает ограниченность самой сущности, а именно опору в исследованиях на уже извлеченные топонимы, что почти не решает задачу надежного автоматического извлечения сложных пространственных упоминаний из различных корпусов информации.

Б) NER и адаптация моделей к нестандартным корпусам

Качество распознавания сущностей определяется и архитектурой модели, и свойствами корпуса литературы. Keraghel, Morbieu и Nadif описывают развитие NER от систем на основе правил к трансформерам и большим языковым моделям и отдельно подчеркивают значимость малого количества размеченных данных. Песенные тексты как раз представляют случай сильного расхождения с типовыми обучающими корпусами.

Проблему такого расхождения особенно ясно показывает Атнашев Т. и др. На материале дневников авторы демонстрируют, что модели, обученные на новостных корпусах, теряют качество на нестандартных русских текстах. Это прямой аргумент в пользу того, что русскоязычные песни нельзя рассматривать как обычный корпус, они требуют собственной разметки и отдельной настройки модели. Схожий вывод на песенном материале делают Sánchez de Lamadrid и Garrido-Merchán. Они показывают, что сленг, метафоры и культурно специфические двойные смыслы делают недостаточными словарные и основанные на жестких правилах подходы, тогда как дообучение GPT на небольшом специально собранном корпусе дает заметный прирост качества.

Исходя из анализа этих исследований, становится понятно, что ключевая проблема состоит не в выборе «лучшей» модели, а в соответствии модели корпусу. Однако для нашей задачи нужно не только выделить локацию, но и определить, что считать пространственным упоминанием, как снимать неоднозначность и как связывать выражение с конкретным местом.

В) Геопарсинг, распознавание локационных упоминаний и разрешение топонимов

Третий блок задает техническую рамку исследования. Gritta, Pilehvar и Collier рассматривают геопарсинг как двухэтапный процесс: сначала из текста выделяются топонимы, затем они соотносятся с конкретными географическими координатами. Топоним нельзя понимать только как простое название места, в реальных текстах важны контекст и тип употребления. Поэтому они предлагают более детальную классификацию топонимов, новую систему оценки и специальный корпус данных. Для исследования это релевантно, поскольку позволяет рассматривать задачу как более сложную обработку пространственной информации в тексте, а не как обычный NER.

Обзор Hu et al. дополняет эту рамку, показывая, что первый шаг такой обработки – распознавание пространственных упоминаний. К ним относятся топонимы и более сложные описания места, включающие направление, расстояние и пространственные связи. Они также отмечают сложность неформальной специфики, как звучало ранее. В нашем случае, неформальная специфика проявляется в песенных текстах, так как пространственно значимыми могут быть не только официальные названия, но и контекстные описания мест. Похожую проблему с другой стороны показывает DeLozier et al., даже в специально размеченных корпусах сохраняются неоднозначность, размытость границ задачи и нехватка подходящих данных.

Дальнейшие работы Hu et al. показывают переход к большим языковым моделям. Авторы доказывают, что обычные модели плохо выделяют полные описания места, тогда как сочетание языковой модели с географическим знанием заметно улучшает результат. Главный шаг – модель сначала восстанавливает, какое именно место имеется в виду, а затем результат уточняется с помощью внешних географических баз. Тем самым современная литература движется от базовых NER к гибридным подходам, сочетающим языковую модель и различное знание.

Вывод

Исходя из литературного обзора, исследование находится на пересечении трех главных направлений. Оно рассматривает песенные тексты как источник пространственных образов города, приходит к тому, что для этого требуется самостоятельно размеченный датасет и дообучение модели, а также применяется логика геопарсинга, где важно не только выделить топоним, но и привести его к стандартизованному виду, снять неоднозначность и связать с конкретным объектом на карте.

Методы

- 1) На первом этапе предполагается **подготовка и разметка корпуса песенных текстов**. Литература по NER показывает, что большинство существующих датасетов построено на новостях, научных текстах и Википедии, поэтому перенос моделей на другой жанр требует отдельного корпуса и отдельной процедуры адаптации. Корпус песенных текстов будет размечаться вручную или в формате LLM-assisted с последующей человеческой верификацией.
- 2) На втором этапе предполагается **предобработка текстов**. Поскольку лирические тексты часто бывают плохо капитализированы, неформальны и содержат шум, качество стандартного NER заметно падает.
- 3) На третьем этапе используется **двухуровневая схема извлечения топонимов**. В качестве простого baseline можно использовать готовые NER-инструменты для русского языка. (Используем Natasha, DeepPavlovBERT NER, Stanza и spaCy). Однако основным методом в исследовательской работе выступает не готовый NER «из коробки», а **дообученная open-source LLM (в нашем случае Qwen/Qwen3.5-9B)**, поскольку исследования по domain adaptation показывают, что именно fine-tuning помогает модели работать со сленгом, метафорами,

культурно-специфическими выражениями и нестандартными конструкциями. Содержательно основная модель должна извлекать не только отдельные «официальные» топонимы, но и **полные пространственные описания**, если они встречаются в тексте.

- 4) После извлечения топонимов необходим этап **нормализации и геокодирования**. Здесь наиболее обоснован именно гибридный подход, а не попытка решать все только силами LLM, поскольку LLM удобны для восстановления однозначной ссылки на место из контекста, но не обладают полным geo-knowledge, и поэтому их следует сочетать с внешними географическими сервисами. Сначала open-source LLM будет дообучаться для определения однозначного референта, а затем результат будет уточняться через GeoNames, Nominatim и QGIS geocoders. (К слову, в том числе поэтому следует приводить к нормализованному виду, а не оставлять в виде «сырых» текстовых фрагментов).
- 5) Наконец, после технической обработки возможен **пространственный и содержательный анализ** распознанных топонимов: частотный анализ, картографирование, анализ контекстов употребления, тематических и эмоциональных связей.

Метрики качества

1. Precision, recall и F1-score




Рис.1. Заметки с брейншторма

Данные

На данном этапе работы сложно точно определить, какой набор данных будет достаточным для выполнения поставленных задач. Однако существует несколько открытых фреймворков и датасетов, которые могут быть потенциально использованы для выполнения проекта:

1. Готовый датасет на HuggingFace – уже собранный массив данных, содержащий 193 тысячи уникальных песен, включая их название, автора и сам текст песни.
2. lyricgenius + spotify – в случае, если для реализации проекта данных из п. 1 будет недостаточно, то есть возможность дополнить датасет, обращаясь к SpotifyAPI (затруднительно, учитывая их

ограничения, но любой другой сервис также может подойти) или уже выгруженные данные, в которых редко указан текст песни, однако его можно получить используя Genius.

3. Альтернативные датасеты: например, Russian Rap 2017-2022 dataset⁴. Они значительно меньше по объему и частично содержат композиции уже существующие в массиве из п. 1, однако они так же содержат отсутствующие там же композиции, что позволит увеличить имеющуюся выборку.

Ограничения

На данный момент основным ограничением выступает ограниченность данных, поскольку из указанных почти 200 тысяч песен лишь малая часть удовлетворяет требованиям исследования (текст песни на русском, в тексте песни имеется информация о географической локации и т.п.).

⁴ <https://www.kaggle.com/datasets/timursharifullindata/russian-rap-2017-2022-dataset>

Список литературы

1. Колмогорова, А. В. (2025). Топонимы в советском песенном дискурсе (1964–1991): корпусное исследование. Вопросы ономастики, 22(2), 148–182.
https://doi.org/10.15826/vopr_onom.2025.22.2.020
2. Sánchez de Lamadrid, D. Z., & Garrido-Merchán, E. C. (2026). Fine-tuning large language models for automatic detection of sexually explicit content in Spanish-language song lyrics [Preprint]. arXiv.
<https://arxiv.org/abs/2602.05485>
3. Kuo, A.-T., & Samet, H. (2021). MusicStand: Listening to song lyrics using a map query interface. In Proceedings of the 29th International Conference on Advances in Geographic Information Systems (SIGSPATIAL '21) (4 pp.). Association for Computing Machinery. <https://doi.org/10.1145/3474717.3484211>
4. Hu, X., Kersten, J., Klan, F., & Farzana, S. M. (2026). Toponym resolution leveraging lightweight and open-source large language models and geo-knowledge. International Journal of Geographical Information Science, 40(3), 670–697. <https://doi.org/10.1080/13658816.2024.2405182>
5. Gritta, M., Pilehvar, M. T., & Collier, N. (2020). A pragmatic guide to geoparsing evaluation: Toponyms, named entity recognition and pragmatics. Language Resources and Evaluation, 54, 683–712.
<https://doi.org/10.1007/s10579-019-09475-3>
6. Keraghel, I., Morbieu, S., & Nadif, M. (2024). Recent advances in named entity recognition: A comprehensive survey and comparative study [Preprint]. HAL. <https://hal.science/hal-04488194v2>
7. Heuser, R., Moretti, F., & Steiner, E. (2016). The emotions of London. Pamphlets of the Stanford Literary Lab, 13, 1–10.
8. DeLozier, G., Wing, B., Baldridge, J., & Nesbit, S. (2016). Creating a novel geolocation corpus from historical texts. In Proceedings of LAW X: The 10th Linguistic Annotation Workshop (pp. 188–198). Association for Computational Linguistics.
9. Hu, X., Zhou, Z., Li, H., Hu, Y., Gu, F., Kersten, J., Fan, H., & Klan, F. (2023). Location reference recognition from texts: A survey and comparison. ACM Computing Surveys, 56(5), Article 112.
<https://doi.org/10.1145/3625819>
10. Hu, Y., Mai, G., Cundy, C., Choi, K., Lao, N., Liu, W., Lakhanpal, G., Zhou, R. Z., & Joseph, K. (2023). Geo-knowledge-guided GPT models improve the extraction of location descriptions from disaster-related social media messages. International Journal of Geographical Information Science, 37(11), 2289–2318.
<https://doi.org/10.1080/13658816.2023.2266495>
11. Атнашев, Т., Ганеева, В., Казаков, Р., Матяш, Д., Сонкин, М., Волошина, Е., Сериков, О., & Артемова, Е. (2022). Размечено: Распознавание именованных сущностей в цифровом архиве дневников «Прожито». In Материалы Пятой международной конференции по компьютерной лингвистике в Болгарии (CLIB 2022) (с. 22–38).