

Кияница Владислав Игоревич (ПЗАД-4)
Злобин Дмитрий Игоревич (ПЗАД-4)

Юрова Ксения Валерьевна (ПЗАД-4)
Холодов Тимур Алексеевич (ПЗАД-3)

Руководитель проекта – Блуменау Марк Ильич

Пространственная репрезентация российских городов в песенных текстах: анализ топонимов с использованием LLM¹

Ключевые слова

LLM, NLP, fine-tuning, toponym, geocoding, toponym resolution

Актуальность

Актуальность исследования определяется тем, что сегодня в гуманитарных и социальных науках все более востребованными становятся методы анализа нереактивных данных, то есть данных, которые возникают независимо от исследователя и фиксируют уже существующие в обществе смыслы, представления и культурные формы. Одним из таких источников являются тексты песен, поскольку в них отражаются устойчивые образы, например, города. В записанных текстом данных содержатся устоявшиеся представления о его районах, улицах, знаковых местах и символических границах. Для городской тематики это позволяет рассматривать культурные тексты как источник сведений о том, как пространство воспринимается, называется и наделяется значением.

При этом, развитие больших языковых моделей открывает новые возможности для автоматической обработки подобных данных, в том числе для извлечения сложных и нестандартных упоминаний городских топонимов из текстов, написанных в свободной, разговорной или художественной манере. В результате становится возможным перейти от отдельных наблюдений к системному анализу: выявлять, какие локации чаще всего появляются в песнях, как они распределены в пространстве, какие эмоциональные и тематические ассоциации с ними связаны, как меняется их упоминаемость во времени и какой образ складывается в музыкальном представлении о городе. Тем самым, актуальность работы связана и с развитием цифровых методов в социальных науках, урбанистике² и Digital Humanities³, и указывает на потенциальную возможность предложить технически обоснованный способ изучения символической репрезентации городов на материале песенных текстов.

¹ <https://github.com/kseniyayurova/iad>

² <https://sysblok.ru/category/urban/>

³ https://sysblok.ru/category/digital_humanities/

Исследовательская проблема

Несмотря на активное развитие Digital Humanities и рост интереса к использованию методов машинного и глубинного обучения в гуманитарных и социальных науках, в российском контексте пока слабо разработаны подходы, позволяющие автоматически извлекать и анализировать пространственные упоминания города в неформальных текстах. Особенно это касается песенных текстов, где названия локаций часто употребляются в разговорной, сокращенной, сленговой или контекстной форме, что в разы затрудняет их распознавание стандартными NER-моделями. Иными словами, существующие инструменты автоматического извлечения именованных сущностей недостаточно хорошо подходят для работы с песенными текстами как с источником данных о символическом и эмоциональном восприятии города, что создает необходимость разработки более адаптивного технического подхода, основанного на дообучении LLM-модели, который позволил бы распознавать топонимы в сложных языковых контекстах.

Исследовательский вопрос

Как дообучить LLM-модель для работы с неформальными, контекстными и сленговыми упоминаниями топонимов городов России в песенных текстах?

Объект

Русскоязычные песенные тексты, в которых упоминаются пространственные локации и топонимы.

Предмет

Дообучение LLM-модели для извлечения топонимов из русскоязычных текстов песен и оценка качества ее работы.

Концептуализация основных понятий

LLM - предобученная нейросетевая модель, обладающая общими знаниями о языке.

NER (Named entity recognition) - технология в области искусственного интеллекта и компьютерной лингвистики, связанная с извлечением и классификацией именованных сущностей (имен, локаций, организаций, известных личностей и т.д.) из текстов на естественном языке.

Fine-tuning - процесс адаптации LLM к конкретной задаче извлечения топонимов на специализированном размеченном корпусе песенных текстов. В отличие от использования модели “как есть”, дообучение позволяет учитывать языковую специфику, в том числе

разговорные, сокращенные, сленговые и контекстно существующие формы упоминания локаций.

Топоним - языковое обозначение географического объекта, которое может быть соотнесено с определенной локацией. В данной работе под топонимами понимаются официальные географические названия, а также их сленговые, контекстные формы и сокращения.

Извлечением географической информации - процесс автоматического обнаружения в тексте фрагментов, содержащих пространственно значимую информацию. Этот процесс включает прежде всего выделение топонимических упоминаний из текста, их последующую нормализацию и подготовку к географической интерпретации.

Обучающий датасет - корпус песенных текстов, для которых сформирован эталонный список сущностей в указанном формате.

Цель

Дообучить и оценить LLM-модель для извлечения топонимов городов России из песенных текстов, включая их неформальные и контекстные упоминания.

Задачи

1. Собрать массив песенных текстов, содержащих упоминания локаций и топонимов городов и мест в них в России.
2. Подготовить и разметить данные для дообучения модели на задаче распознавания топонимов.
3. Дообучить LLM-модель для извлечения топонимов городов России из песенных текстов.
4. Проверить качество работы модели на корпусе песенных текстов и выявить особенности распознавания топонимов в сложных языковых случаях.
5. Сравнить и описать результаты дообученной LLM и базовой LLM на тестовой выборке.
6. Провести постобработку извлеченных топонимов, включая их нормализацию и приведение к единому виду.
7. Выполнить геокодирование распознанных топонимов и сопоставить их с конкретными объектами городской среды.
8. Провести анализ полученных данных, включая частоту упоминаний, пространственное распределение, эмоциональную окраску и тематические связи топонимов.
9. Визуализировать результаты исследования в виде карты распознанных локаций с модулем фильтрации и отображением дополнительно определенных характеристик.

Основная гипотеза

Дообучение LLM-модели на специализированно размеченном корпусе русскоязычных песенных текстов позволит повысить качество извлечения топонимов по сравнению с базовыми NER-подходами, особенно в случаях сленговых, сокращенных и контекстных упоминаний.

Обзор литературы

Цель данного раздела – показать, как в существующих работах решалась задача распознавания, нормализации и геокодирования топонимов из текстов песен.

NER и адаптация моделей к нестандартным текстам

Качество распознавания сущностей определяется и архитектурой модели, и свойствами корпуса литературы. Развитие NER происходит от систем на основе лингвистических правил и уже активно использует сверточные, рекуррентные и трансформерные нейронные сети⁴. Однако в нашем случае важно понимать особенности данных, с которыми нам придется работать. Основная сложность заключается в повышенной метафоричности, “закодированности” локаций в обследуемом типе текстов. Эту же проблему отмечали и ранее при выполнении подобной задачи: традиционные NER-инструменты были натренированы на данных статей из Wikipedia, материалов из новостей и других официальных источников, которые можно было наиболее быстро и просто обработать⁵. Однако за этим стоит специфика работы такого NER: он требователен к оформлению, грамматике текста, так как обучающая выборка обладала именно такими её описывающими характеристиками. В нашем случае песенные тексты как раз представляют случай сильного расхождения с типовыми обучающими корпусами. Также отметим, что в той же статье⁶ авторы прибегали к форматированию текста для повышения корректности распознавания топонимов.

С другой стороны хочется отметить языковой аспект. На материале русскоязычных личных дневников было продемонстрировано, что модели, обученные на новостных корпусах, теряют качество на нестандартных русскоязычных текстах⁷. Авторы отмечают, что готовые инструменты (Natasha, SpaCy и др.) действительно хорошо работают на новостных текстах, но на материале из личных дневников справляются в разы хуже (Ассурасу у лучшей модели при

⁴ Keraghel I., Morbieu S., Nadif M. Recent advances in named entity recognition: A comprehensive survey and comparative study //arXiv preprint arXiv:2401.10825. – 2024.

⁵ Kuo A. T., Samet H. MusicStand: listening to song lyrics using a map query interface // Proceedings of the 29th International Conference on Advances in Geographic Information Systems. – 2021. – С. 446-449.

⁶ Там же

⁷ Atnashev, T. et al. Razmecheno: Named Entity Recognition from Digital Archive of Diaries “Prozhito” //Proceedings of CLIB, – 2022.

распознавании топонимов составляет 54%)⁸. При этом модели с архитектурой трансформера после фاین-тюнинга показывают F1-Score в 0.793⁹. Этого уже достаточно для определения будущего подхода к решению поставленной задачи. Исходя из подхода авторов, бейзлайн при решении нашей задачи аналогично будет состоять как из “коробочной” модели для NER.

Исходя из анализа данных исследований, становится понятно, что ключевая проблема состоит не в выборе «лучшей» модели, а в данных на которых она училась модели – то есть, соответствии обрабатываемому корпусу. Однако в рамках нашего проекта это только часть задачи и кроме выявления и классификации топонимов необходимо также определить связывать выражение с конкретным местом на карте. Перейдем к блоку исследований на эту тему.

Соотнесение топонимов с географическими объектами

Поскольку LLM не обладает всей полнотой знаний в области географии, их использование в качестве самостоятельного геокодера ограничено, а дообучение модели для этой задачи на практике приводит к неудовлетворительным результатам¹⁰. Вследствие этого, наша задача исключает собственное определение координат объекта моделью и сводится к правильному распознаванию топонима и соотнесению его с географическим объектом. Основная проблема, которую выделяют исследователи и которая остается актуальной в рамках нашей работы, проявляется в существовании многообразия объектов с одинаковым названием (в оригинальной статье¹¹ в качестве примера указаны 400 локаций с названием “Victoria Park” в OSM). Для ее решения используется дообученная LLM, которая по контексту восстанавливает текстовую референцию топонима по иерархически более высоким административным принадлежностям (страна, штата, город) и далее результаты уже отправляются во внешние справочники GeoNames, Nominatim и ArcGIS. В нашем случае, в связи с неоднозначностью сленговых выражений и сокращений целесообразно использовать помимо нормализации топонимов, их расшифровку, в случае сленговых выражений и сокращений, реализация которой будет осуществлена как идея, основанная на данном исследовании.

⁸ Там же

⁹ Там же

¹⁰ Hu, X., Kersten, J., Klan, F., & Farzana, S. M. (2026). Toponym resolution leveraging lightweight and open-source large language models and geo-knowledge. *International Journal of Geographical Information Science*, 40(3), 670-697.

¹¹ Там же

Существует и другой подход к решению проблемы омонимов¹²: сначала для каждого топонима генерируется набор кандидатов из базы GeoNames с помощью нескольких режимов поиска – EXACT, FUZZY, CHARACTER N-GRAM, TOKEN, ABBREVIATION и COUNTRYCODE (эти режимы используются не для окончательного выбора объекта, а для расширения охвата и повышения вероятности того, что правильный географический объект вообще попадет в список кандидатов), затем список кандидатов передается в модуль reranking, который, с учётом контекста документа и характеристик самих объектов, выбирает наиболее вероятное соответствие. Методологию работы можно применить в качестве определения локации из нескольких по контексту. Если на основе подхода из прошлой работы¹³ с помощью LLM мы определяем официальную формулировку топонима и сразу же переходим к географическому декодированию локации, то в этой работе – сначала выделяем иерархически менее глобальное в сравнении с предыдущим методом¹⁴ административное образование, который имеется в виду в тексте и аналогично обращаемся за его адресом в справочник (например, станция метро, район и конкретная точка могут называться одинаково и на этом шаге мы уточняем уже конкретный объект исходя из контекста песни).

¹² Zhang, Z., & Bethard, S. (2023, July). Improving toponym resolution with better candidate generation, transformer-based reranking, and two-stage resolution. In *Proceedings of the 12th joint conference on lexical and computational semantics (* SEM 2023)* (pp. 48-60).

¹³ Hu, X., Kersten, J., Klan, F., & Farzana, S. M. (2026). Toponym resolution leveraging lightweight and open-source large language models and geo-knowledge. *International Journal of Geographical Information Science*, 40(3), 670-697.

¹⁴ Там же

Методология

Основным подходом в проекте выступает дообучение LLM в рамках задачи извлечения топонимов из русскоязычных песенных текстов. Перечислим основные категории, а также формирующий их подход для решения данной задачи:

- Единицей входных данных выступает отдельный текст песни. Единицей разметки – сущность (в рамках работы – слово/словосочетание, обозначающее пространственное местоположение) в тексте. Датасет создается в два этапа: сначала разметка составляется при помощи LLM, затем результаты проверяются вручную и приводятся к единому формату. Целевая переменная в исследовании – корректное предсказание списка сущностей для каждого текста.
- Дообучением LLM происходит за счет адаптации предобученной модели на размеченном корпусе. Для работы была выбрана базовая модель Qwen/Qwen3.5-9B. В дальнейшей работе базовая модель может быть изменена, например, на вариацию с большим числом параметров в случае обнаружения более подходящей под цели исследования модели, однако на текущий момент было принято решение остановилась на данной модели, поскольку среди всех экспериментов с доступными для запуска на имеющихся ресурсах open-source моделями она зарекомендовала себя наилучшим образом. В качестве основного способа адаптации планируется использовать fine-tuning или же LoRA. Также произведем попытку применения Prompt tuning как альтернативный вариант дообучения модели.
- Качество модели измеряется через стандартные метрики для задачи распознавания: precision, recall и F1-score как используемые для оценки задачи NER¹⁵. Precision показывает долю корректных объектов среди всех предсказанных моделью. Recall показывает долю объектов из эталонной разметки, которые модель смогла найти. Однако в общем случае мы будем прибегать к использованию F1-score как средней геометрической базовых метрик качества.

¹⁵ Keraghel I., Morbieu S., Nadif M. Recent advances in named entity recognition: A comprehensive survey and comparative study //arXiv preprint arXiv:2401.10825. – 2024.

План выполнения работы

1. Выполняем подготовку и разметку корпуса песенных текстов. Литература по NER показывает, что большинство существующих датасетов построено на новостях, научных текстах и Википедии, поэтому перенос моделей на другой жанр требует отдельного корпуса и отдельной процедуры адаптации¹⁶. Разметка корпуса песенных текстов будет происходить на основе работы LLM (базовая модель - Qwen 3.5-9B) с последующей ручной верификацией.
2. Далее производим предобработку текстов. Поскольку тексты песен могут быть некорректно оформлены с точки зрения регистра символов, содержать неиспользуемые словарный шум, мы можем столкнуться со снижением качества будущей обработки.
3. Нами используется двухэтапный подход к извлечению топонимов. В качестве baseline будем использовать готовые NER-инструменты с поддержкой русского языка (используем Natasha, DeepPavlovBERT и spaCy). Далее произведем дообучение open-source LLM (в нашем случае семейство Qwen, например, Qwen3.5-9B), поскольку именно fine-tuning поможет модели научиться работать со сленгом, метафорами, культурно-специфическими выражениями и нестандартными конструкциями.
4. После извлечения топонимов необходим этап нормализации и геокодирования. Сначала все топонимы будут приведены в единый вид и официальную форму, поскольку в песенных текстах могут быть использованы сленговые выражения и сокращения. Далее будет составлен словарь топонимов и соответствующих им географических объектов с координатами с помощью GeoNames, Nominatim (OSM) или Wikidata.
5. Так как одному топониму может соответствовать несколько географических объектов следующим этапом будет применена LLM модель, которая на основе контекста песни будет отбирать правильный географический объект из списка имеющихся.
6. Наконец, после технической обработки будем применять содержательный анализ распознанных топонимов: визуализация частот, жанровых и эмоциональных связей. В результате будет представлена карта с настраиваемыми фильтрами на основе фреймворка streamlit.

¹⁶ Kuo A. T., Samet H. MusicStand: listening to song lyrics using a map query interface // Proceedings of the 29th International Conference on Advances in Geographic Information Systems. – 2021. – С. 446-449.




Рис.1. Заметки с брейншторма

Данные

На данном этапе работы сложно точно определить, какой набор данных будет достаточным для выполнения поставленных задач. Однако существует несколько открытых фреймворков и датасетов, которые могут быть потенциально использованы для выполнения проекта:

1. Готовый датасет на HuggingFace: `genius-lyrics-russian`¹⁷ – уже собранный массив данных, содержащий 193 тысячи уникальных песен, включая их название, автора и сам текст песни.
2. `lyricgenius + spotify` – в случае, если для реализации проекта данных из п. 1 будет недостаточно, то есть возможность дополнить датасет, обращаясь к `SpotifyAPI` (затруднительно, учитывая их ограничения, но любой другой сервис также может подойти) или уже выгруженные данные, в которых редко указан текст песни, однако его можно получить используя `Genius`.
3. Альтернативные датасеты: например, `Russian Rap 2017-2022 dataset`¹⁸. Они значительно меньше по объему и частично содержат композиции уже существующие в массиве из п. 1, однако они также содержат отсутствующие там же композиции, что позволит увеличить имеющуюся выборку.

Ограничения

¹⁷ <https://huggingface.co/datasets/sevenreasons/genius-lyrics-russian>

¹⁸ <https://www.kaggle.com/datasets/timursharifullindata/russian-rap-2017-2022-dataset>

На данный момент основным ограничением выступает ограниченность данных, поскольку из указанных почти 200 тысяч песен лишь малая часть удовлетворяет требованиям исследования (текст песни на русском, в тексте песни имеется информация о географической локации и т.п.).

Список литературы

1. Atnashev, T. et al. Razmecheno: Named Entity Recognition from Digital Archive of Diaries “Prozhito” //Proceedings of CLIB, – 2022.
2. Kuo A. T., Samet H. MusicStand: listening to song lyrics using a map query interface // Proceedings of the 29th International Conference on Advances in Geographic Information Systems. – 2021. – С. 446-449.
3. Keraghel I., Morbieu S., Nadif M. Recent advances in named entity recognition: A comprehensive survey and comparative study //arXiv preprint arXiv:2401.10825. – 2024.
4. Hu, X., Kersten, J., Klan, F., & Farzana, S. M. (2026). Toponym resolution leveraging lightweight and open-source large language models and geo-knowledge. *International Journal of Geographical Information Science*, 40(3), 670-697.
5. Zhang, Z., & Bethard, S. (2023, July). Improving toponym resolution with better candidate generation, transformer-based reranking, and two-stage resolution. In *Proceedings of the 12th joint conference on lexical and computational semantics (* SEM 2023)* (pp. 48-60).